

Modèles et techniques en programmation parallèle hybride et multi-cœurs

Marc Tajchman

CEA - DEN/DM2S/STMF/LMES

10/08/2020


Rappels sur l'architecture matérielle

Programmation séquentielle efficace

Rappels sur l'architecture matérielle

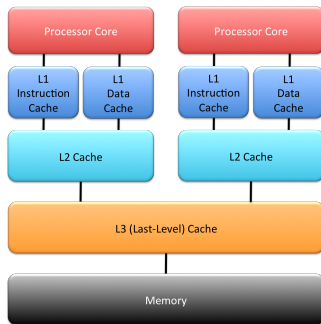
On peut voir la structure d'une machine de calcul à différentes échelles:

Vue globale: un ensemble de nœuds de calcul chacun contenant un ou plusieurs processeurs et de la mémoire, les nœuds sont connectés par un réseau:



(les machines les plus puissantes actuellement contiennent plusieurs centaines de milliers de nœuds)

Vue interne d'un nœud (variable suivant le modèle de processeur et la génération utilisée):

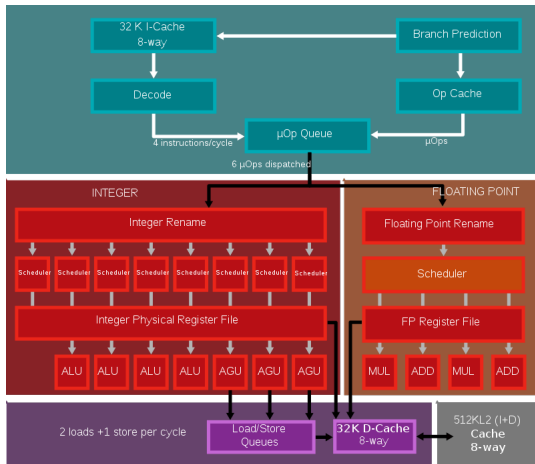


Memory : mémoire de travail pour vos données.

L1-L2-L3 : mémoires à accès plus rapide mais plus petites

La gestion des mémoires (copie, contrôle de cohérence, etc.)
est faite par un contrôleur mémoire

Vue interne d'un cœur (variable suivant le modèle de processeur et la génération utilisée):



AMD - Zen2 μ arch (simplifié)

Situation actuelle (et encore pour plusieurs années):

vitesse de calcul (d'un processeur)

\approx vitesse de la mémoire interne (registres) du processeur

> vitesse des différentes mémoires cache, intermédiaires entre le processeur et la mémoire centrale du nœud

*(vitesse $L1 > L2 > L3$,
taille $L1 < L2 < L3$)*

» vitesse de la mémoire centrale d'un nœud

» vitesse du réseau qui connecte les nœuds

Fonctionnement :


- ▶ Quand un cœur a besoin d'une donnée, il la demande au gestionnaire mémoire.
- ▶ Le gestionnaire mémoire regarde si la donnée est dans la mémoire cache L1, L2 ou L3 de ce processeur, sinon le bloc de la mémoire centrale qui contient la donnée est recopié dans la mémoire cache (dans L3, puis L2 et L1).
- ▶ Ensuite, la donnée est recopiée dans un registre de ce cœur.

- ▶ Quand un cœur a modifié une donnée, il le notifie au gestionnaire mémoire
- ▶ Le gestionnaire mémoire recopie la donnée vers la mémoire cache (L1, L2 puis L3) et vers la mémoire centrale
- ▶ Il vérifie aussi qu'une autre copie de la donnée n'existe pas dans la mémoire cache d'un autre cœur.
- ▶ Si c'est la cas, les autres copies sont mises à jour

Cette gestion peut représenter une partie importante du temps d'exécution (pour assurer la cohérence des différentes parties de la mémoire et leurs mises à jour correctes).

Exemple:

```
void f() {  
    double a, b;  
  
    a = sin(3.1416);  
    b = 2.4 * a;  
  
    // bcp d'instructions  
  
    b = b * 2;  
}
```



Programmation séquentielle efficace

Pour obtenir un code efficace (en temps d'exécution), il faut:

- ▶ **utiliser les algorithmes les plus efficaces possible (pas couvert par ce cours)**
- ▶ **organiser le placement des données (améliorer la localité spatiale)**
- ▶ **organiser la séquence d'instructions (améliorer la localité temporelle)**
- ▶ **écrire les instructions pour qu'elles soient les plus rapides (utilisation du // interne des processeurs, éviter si possible les tests)**

Localité spatiale

Règle: **autant que possible, utiliser des zones mémoires proches les unes des autres dans une séquence d'instructions**

Le transfert entre mémoire centrale et mémoire cache se fait par bloc de données.

Donc, si une donnée est à côté d'une donnée qui vient d'être utilisée (et donc transférée en mémoire cache), un nouveau transfert sera peut-être inutile.

Exemple: voir TP 1

Localité temporelle

Règle: autant que possible, pour une zone mémoire, les instructions qui l'utilisent doivent s'exécuter de façon rapprochée dans le temps

La mémoire cache étant de petite taille, le gestionnaire mémoire, s'il a besoin de place, effacera dans la mémoire cache les données les plus anciennes.

Si une donnée est utilisée par plusieurs instructions proches dans le temps, elle sera maintenue plus longtemps en mémoire cache (et donc nécessitera moins de transferts)

Exemple: voir TP 1

Utilisation du // interne au processeur

Règles:

- ▶ essayer de rassembler plusieurs instructions simples en une seule (quand cela a un sens),
utiliser au maximum la présence de plusieurs unités de calcul (additionneurs, multiplicateurs, etc) dans un cœur
- ▶ essayer d'éviter les tests
simplifier le travail du processeur (enchaînement des instructions le plus déterministe possible).

Exemple: remplaceur

```
for (i=0; i<n; i++) {  
    u[i] = u0[i];  
    if (terme1) u[i] += a*v[i];  
    if (terme2) u[i] += b*w[i];  
}
```

par:

```
if (terme1) aa = a; else aa = 0.0;  
if (terme2) bb = b; else bb = 0.0;  
for (i=0; i<n; i++) {  
    u[i] = u0[i] + aa*v[i] + bb*w[i];  
}
```