Modèles et techniques en programmation parallèle hybride et multi-cœurs

Introduction au parallélisme multithreads

Marc Tajchman

CEA - DEN/DM2S/STMF/LMES

10/08/2020

Parallélisme multi-threads en mémoire partagée

- Le but du parallélisme multithreads est de découper l'ensemble des instructions en plusieurs parties et d'exécuter (le plus possible) simultanément ces différentes parties par des threads (exécutions) sur des cœurs différents.
- On appellera la version du code non parallélisé : "séquentiel".
- Dans le cas le plus simple, le nombre de threads est égal au nombre de cœurs. Mais on peut utiliser un nombre de threads différent du nombre de cœurs.
- En mémoire partagée signifie que différents groupes d'instructions travaillent sur des données contenues dans la même mémoire. Il faut donc faire attention que les modifications faites par certaines instructions ne perturbent pas les données utilisées par d'autres instructions.

En général, il n'est pas possible de rendre "multithreads" la totalité d'un code. Il sera en général composé d'une succession de parties (ou régions) qui devront rester séquentielles et de parties (ou régions) multithreadées.

On aura un enchaînement du type:

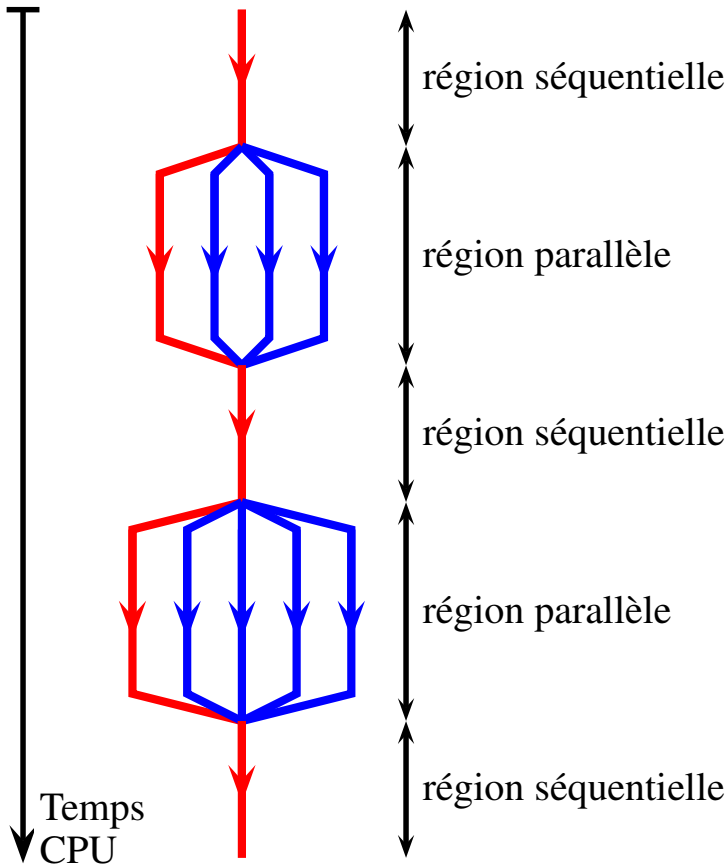

thread_0 : fil d'exécution rouge, actif durant toute l'exécution

thread_i $(i > 0)$: un des fils d'exécution bleus, actifs seulement dans des parties parallèles

Formellement dans une région parallèle :

On veut exécuter en parallèle, N instructions

$$I = \{I_i(u), i = 1..N\}$$

où u est une structure de données commune.

On regroupe l'ensemble des instructions en n_G groupes

$$G_k = \{I_{i_j}(u), \quad i_j \in (1..N), \quad j = 1, .., N_k\} \quad k = 1..n_G$$

de telle sorte que

$$\begin{aligned} G_{k'} \bigcap G_{k''} &= \varnothing \quad si\ k' \neq k'' \\ \bigcup_{k=1}^{k=n_G} G_k &= I \end{aligned}$$

Autrement dit:

Chaque instruction doit être exécutée une et une seule fois

- Autant que possible, il faut pouvoir exécuter les différents groupes d'instructions de façon indépendante (c'est le système qui décidera de démarrer un groupe, en fonction des cœurs disponibles)
- A l'intérieur d'un groupe, les instructions sont exécutées séquentiellement
- Il faut déterminer quelles sont les données partagées entre les groupes et celles qui sont privées (utilisées par un seul groupe).

Ce dernier point est souvent le plus complexe.

Exemple 1:

On peut découper une boucle:

```
for (i=0; i<N; i++)
  v[i] = f(a, u[i]);
```

en 3 parties (par exemple),
avec $0 = N0 \leq N1 \leq N2 \leq N3 = N$:

```
for (i=N0; i<N1; i++)
  v[i] = f(a, u[i]);
```

1^{er} groupe d'instructions à exécuter par le 1^{er} thread

```
for (i=N1; i<N2; i++)
  v[i] = f(a, u[i]);
```

$2^{ème}$ groupe d'instructions à exécuter par le $2^{ème}$ thread

```
for (i=N2; i<N3; i++)
  v[i] = f(a, u[i]);
```

$3^{ème}$ groupe d'instructions à exécuter par le $3^{ème}$ thread

Il faut examiner l'utilisation de toutes les données sinon on risque de tomber sur des erreurs difficiles à corriger.

Donnée	**Comportement**
N0, N1, N2, N3, a	Utilisées par plusieurs threads mais constantes dans l'algorithme, on peut les partager entre les threads
u	u est constant et donc peut être partagé
v	v varie dans l'algorithme, mais comme chaque thread modifie une partie différente du vecteur, v peut être partagé.
i	i prend des valeurs différentes dans les threads (i = N0 à N1-1 dans le premier thread, i=N1 à N2-1 dans le second thread, etc.), il faut donc utiliser des variables différentes qui représentent i dans les différents threads. i est dit "variable privée".

L'algorithme doit être modifié comme suit:

```
for (i0=N0; i0<N1; i0++)
        v[i0] = f(a, u[i0]);

for (i1=N1; i1<N2; i1++)
        v[i1] = f(a, u[i1]);

for (i2=N2; i2<N3; i2++)
        v[i2] = f(a, u[i2]);
```

Voir plusieurs variantes dans l'Exemple 1, codé en OpenMP. Dans le même exemple, on trouvera la façon habituelle (et beaucoup plus simple) de coder une boucle en OpenMP.

Exemple : si `u` et `v` sont des vecteurs de taille `n > 4`, on veut calculer la boucle `for`:

$$\begin{array}{l} for(i = 1; i < n - 1; i + +) \\ \quad v_i = (u_{i-1} + 2 * u_i + u_{i+1})/4; \end{array} \tag{1}$$

On va examiner en détail le calcul simultané sur 2 cœurs des 2 expressions

$$\begin{aligned} v_2 &= (u_1 + 2u_2 + u_3)/4 \\ v_3 &= (u_2 + 2u_3 + u_4)/4 \end{aligned}$$

On supposera que chaque cœur possède sa mémoire cache de taille 8 (4 lignes de cache de taille 2).

1. Avant d'exécuter les 2 instructions :

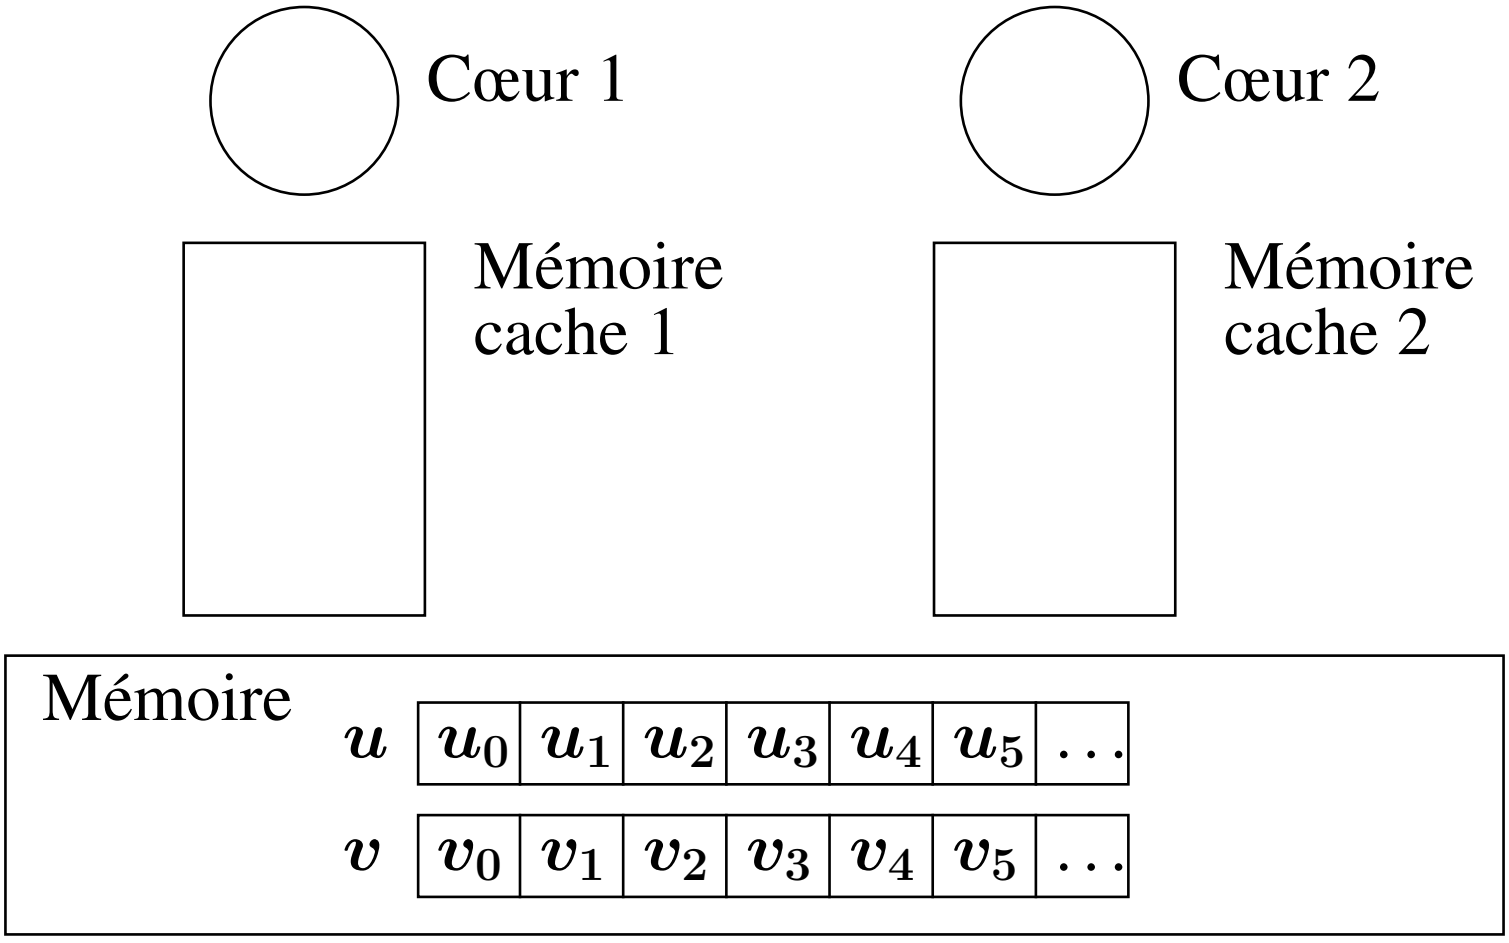

2. Les blocs qui contiennent les composantes utilisées sont recopiés dans les mémoires cache :

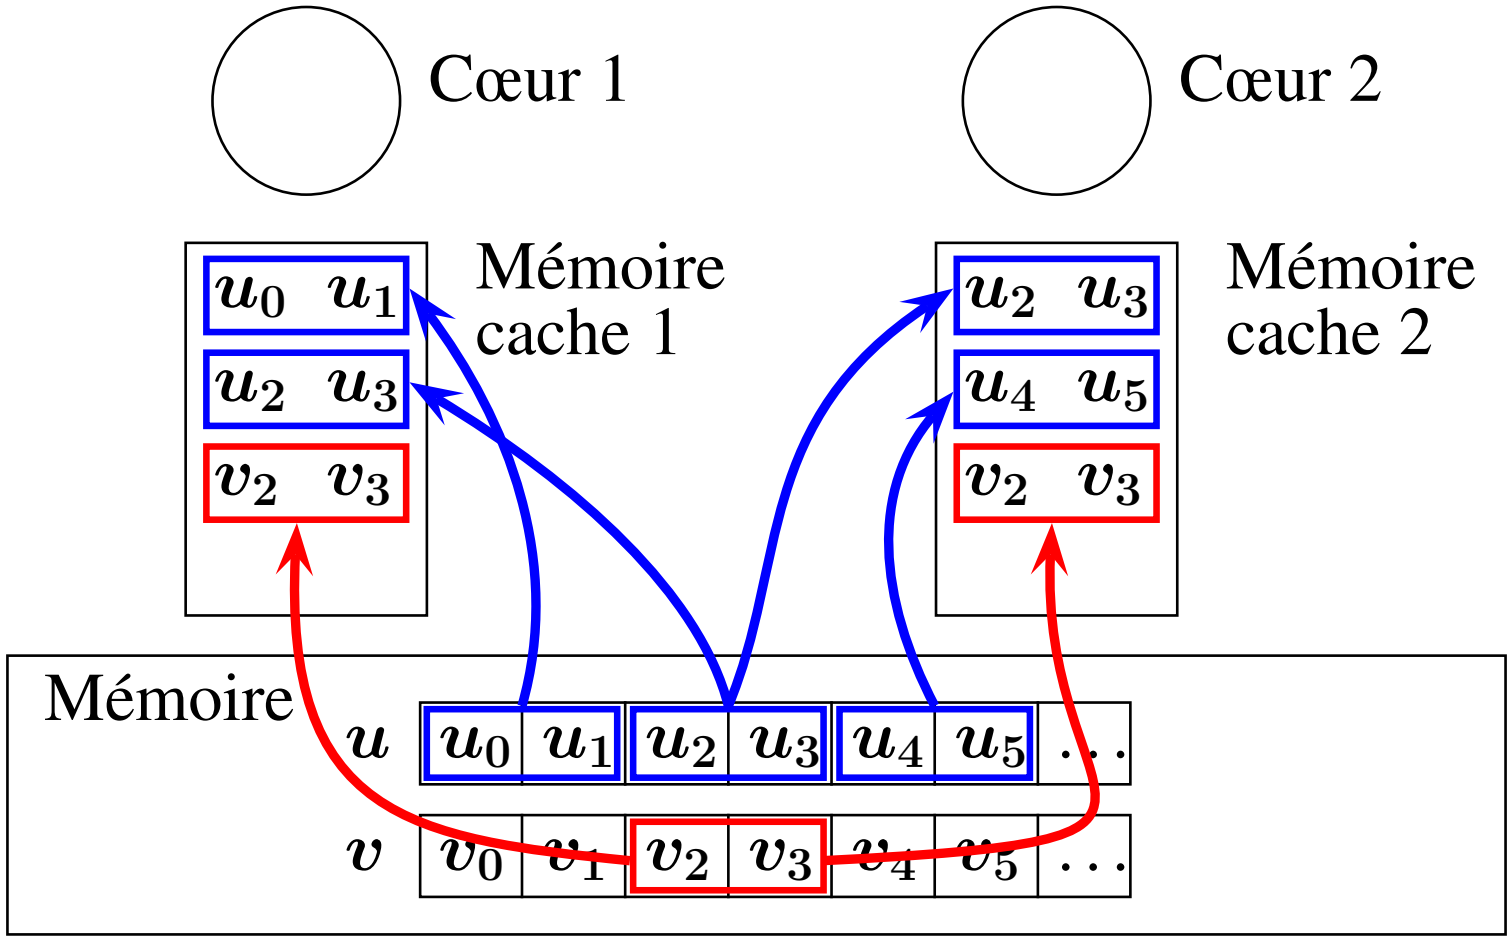

3. Les composantes de u sont recopiées dans les mémoires internes des processeurs et les résultats sont mis à la place de composantes de v:

$$w_2 = (u_1 + 2u_2 + u_3)/4 \qquad w_3 = (u_2 + 2u_3 + u_4)/4$$

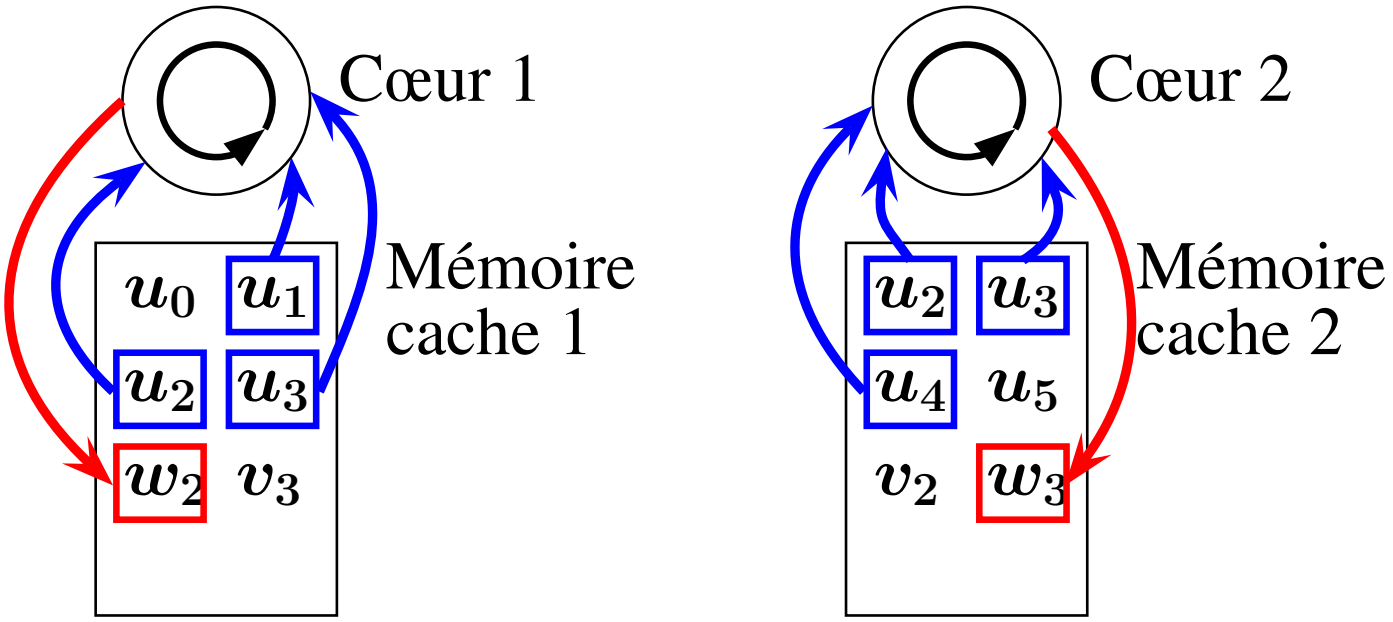

Mémoire

u	u_0	u_1	u_2	u_3	u_4	u_5	$\ldots$
v	v_0	v_1	v_2	v_3	v_4	v_5	$\ldots$

4. Les blocs qui contiennent les résultats sont copiés dans la mémoire centrale. ⚠ Le résultat est indéterminé.

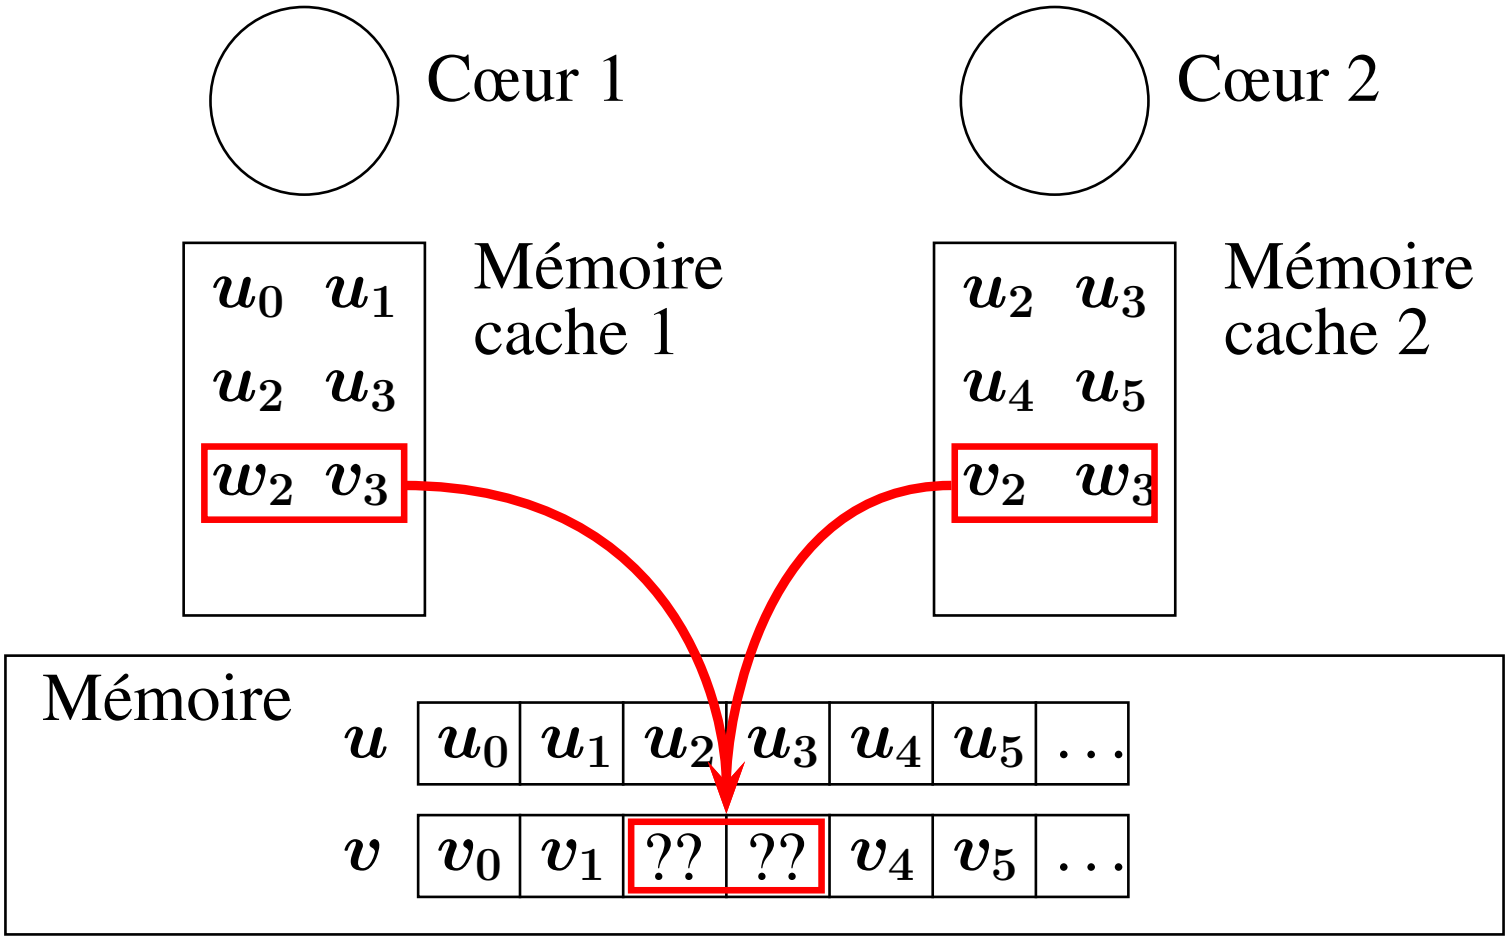

La collision vient du fait que 2 caches différents contiennent chacun un bloc (partiellement) différent qui sera recopié dans la mémoire centrale au même endroit.

Tous les ordinateurs dont les processeurs ont plusieurs cœurs, appliquent un algorithme pour vérifier et rétablir la cohérence de cache :

> *Si deux lignes de cache dans deux mémoires cache correspondent au même emplacement dans la mémoire centrale, on garde les valeurs les plus récentes.*

3 bis. On rétablit la cohérence de cache : w_2 dans le cache 1 est copié à la place de v_2 dans le cache 2 et w_3 dans le cache 2 est copié à la place de v_3 dans le cache 1

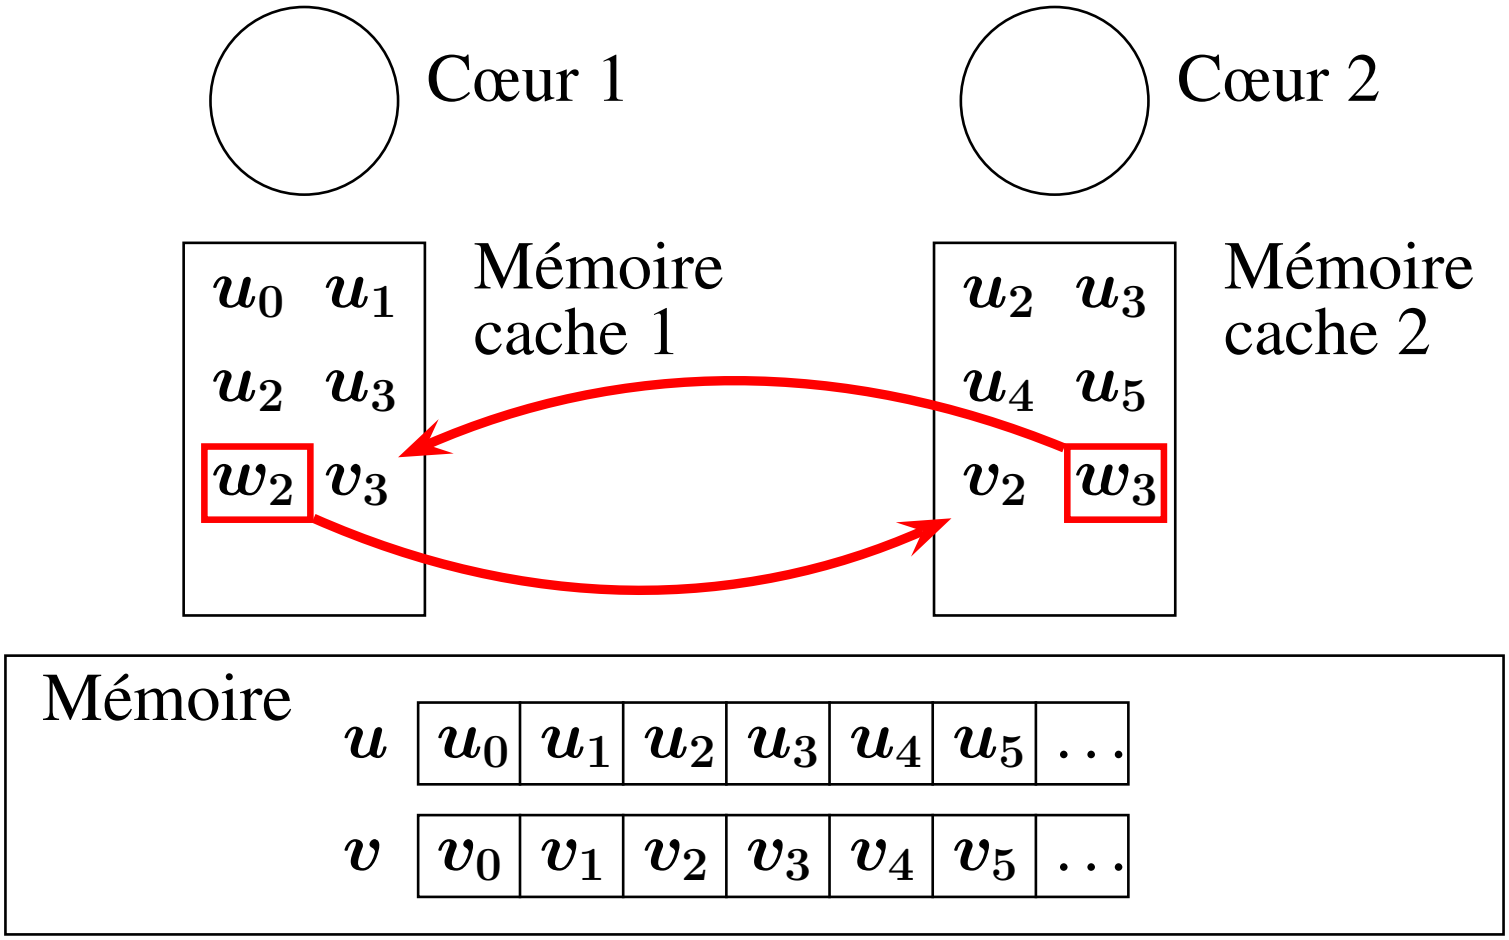

Grace à l'étape de cohérence de cache les résultats seront corrects mais le maintien de la cohérence de cache prend du temps et diminue l'efficacité du parallélisme multithreads.

On essaie de faire en sorte que les caches ne contiennent pas des copies des mêmes blocs mémoires (dans ce cas pas besoin de contrôler la cohérence des caches)

D'où la règle supplémentaire :

Règle:

Les zones mémoire modifiées par deux threads différents au même instant doivent être distinctes (sinon les résultats peuvent être faux) et assez éloignées (pour diminuer le cout du maintien de la cohérence de cache)

Exemple: Parcours d'un vecteur u de taille N (multiple de 2) par 2 threads (on suppose que les threads avancent à la même vitesse).
Le parcours suivant :

Thread0			Thread1		
u_0	$=$	$\ldots$	u_1	$=$	$\ldots$
u_2	$=$	$\ldots$	u_3	$=$	$\ldots$
u_4	$=$	$\ldots$	u_5	$=$	$\ldots$
$\ldots$		$\ldots$			
u_{N-2}	$=$	$\ldots$	u_{N-1}	$=$	$\ldots$

est moins bon que le suivant:

Thread0			Thread1		
u_0	$=$	$\ldots$	$u_{N/2}$	$=$	$\ldots$
u_1	$=$	$\ldots$	$u_{N/2+1}$	$=$	$\ldots$
u_2	$=$	$\ldots$	$u_{N/2+2}$	$=$	$\ldots$
$\ldots$			$\ldots$		
$u_{N/2-1}$	$=$	$\ldots$	u_{N-1}	$=$	$\ldots$

Dans le permier parcours, les 2 threads travaillent sur des composantes proches u_k, u_{k+1}

Dans le second parcours, les 2 threads travaillent sur des composants éloignées (on suppose N grand) : $u_k, u_{k+N/2}$

Donc la cohérence de cache sera plus couteuse pour le premier parcours.

Rappels sur OpenMP

Le principal (mais pas le seul) outil pour coder du parallélisme multithreads est OpenMP.

Pour l'exemple vu plus haut, on ajoute avant la boucle, le pragma (ligne qui commence par `#pragma`)

```
#pragma omp parallel for
for (i=1; i<n-1; i++)
  v[i] = (u[i-1] + 2*u[i] + u[i+1])/4;
```

Si on compile le code sans l'option de compilation OpenMP, le pragma sera ignoré, donc on peut utiliser le même code source pour un exécutable séquentiel et multithreads.

Avantages:

- un seul code source pour les versions parallèle ou séquentiel
- on peut choisir les boucles qu'on veut paralléliser ou non (parallélisation incrémentale)
- facile à coder

Désavantages et difficultés:

- les performances sont parfois décevantes
- attention aux variables partagées par différentes itérations d'une boucle
- pas beaucoup de contrôle sur le placement des threads et sur le découpage en sous-boucles

Pour compiler du code utilisant OpenMP, on utilise une option de compilation (qui dépend du compilateur : -fopenmp pour gcc/g++/gfortran).

Pour exécuter un code utilisant plusieurs threads, il y a plusieurs possibilités:

- définir une variable d'environnement `OMP_NUM_THREADS`, par exemple :

```
OMP_NUM_THREADS=5 ./code.exe
```

- appeler dans le code source la fonction

```
omp_set_num_threads(5);
```

Exemple OpenMP 1

```
#pragma omp parallel
{
  std::cout << "Bonjour" << std::endl;
}
```

- avant d'arriver au pragma, on est dans la partie séquentielle (seul le thread 0 est actif);
- quand l'exécution arrive sur la ligne `#pragma`, le système crée (ou active) $N-1$ threads (N est égal au nombre de cœurs ou à la valeur de `OMP_NUM_THREADS` si cette variable d'environnement existe);
- chacun des N threads exécute la partie parallèle (le bloc d'instructions contenu entre les accolades);
- quand tous les threads sont arrivés à la fin du bloc, les threads s'arrêtent (ou se mettent en pause) sauf le thread 0.

Le code ci-dessus est contenu dans l'Exemple2.
Lire le fichier README.txt pour compiler et exécuter le code.

Relancer plusieurs fois l'exécution, expliquer ce qui est affiché.

Une variante se trouve dans l'Exemple2b.
Cette variante affiche aussi le numéro du thread qui écrit le message.
Faire les mêmes tests que dans l'Exemple2.